

Universidade Federal do Paraná Laboratório de Estatística e Geoinformação - LEG



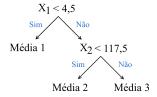
Métodos baseados em árvores

Eduardo Vargas Ferreira

Introdução



 Árvore de decisão é o conjunto de regras que envolvem a estratificação ou segmentação do espaço de predição em regiões simples;

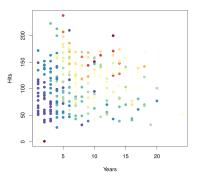


 Nesta seção vamos descrever os métodos baseados em árvores no contexto de regressão e classificação.

Exemplo: Hitters data set - Baseball salary



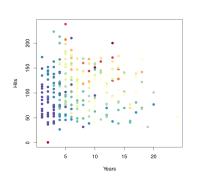
 Queremos prever o Salary dos jogadores baseado nos Years em que está na Major leagues e número de Hits no ano;

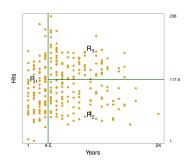


 Os salários mais baixos são codificados pelas cores azul e verde, e mais altos pelas cores amarelo e vermelho;

Exemplo: Hitters data set - Baseball salary (eg







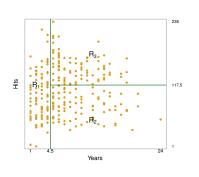
$$R_1 = \{X | Years < 4.5\}$$

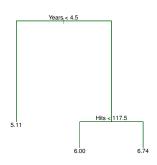
$$R_2 = \{X | Years \ge 4.5, Hits < 117.5\}$$

$$R_3 = \{X | Years \ge 4.5, Hits \ge 117.5\}$$

Exemplo: Hitters data set - Baseball salary (eg







$$R_1 = \{X | \texttt{Years} < 4.5\}$$

$$R_2 = \{X | Years \ge 4.5, Hits < 117.5\}$$

$$R_3 = \{X | Years \ge 4.5, Hits \ge 117.5\}$$

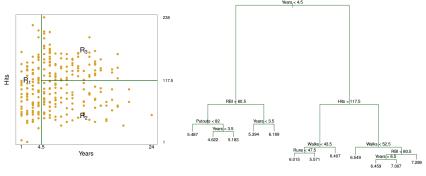
Como o algoritmo funciona?



• O objetivo é encontrar os retângulos R_1, \ldots, R_J que minimiza a:

$$SQRes = \sum_{i:x_i \in R_1(j,s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i:x_i \in R_2(j,s)} (y_i - \hat{y}_{R_2})^2,$$

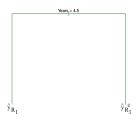
em que
$$R_1(j,s) = \{X | X_j < s\}$$
 e $R_2(j,s) = \{X | X_j \ge s\}.$



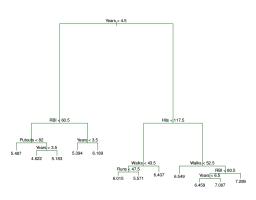
Como o algoritmo funciona?



Alto vício e baixa variância



Baixo vício e alta variância



Cost complexity pruning



• Para cada valor de λ , temos uma subárvore $T \subset T_0$, tal que

$$SQRes_{\lambda} = \sum_{m=1}^{|T|} \sum_{i:x_i \in R_m} (y_i - \hat{y}_{R_m})^2 + \lambda |T|$$

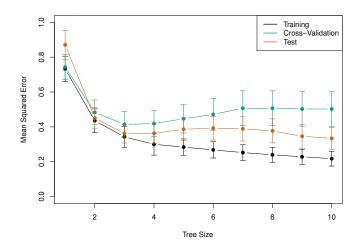
seja o menor possível.

- \star |T| indica o número de **terminal nodes** da árvore T;
- * R_m é o retângulo correspondente ao *m*-ésimo *terminal node*;
- \star \hat{y}_{R_m} é a média das observações dos dados de treino em R_m .
- Selecionamos o valor ótimo, $\hat{\lambda}$, através de validação. Em seguida, obtemos a subárvore utilizando $\hat{\lambda}$.

Exemplo: Hitters data set - Baseball salary



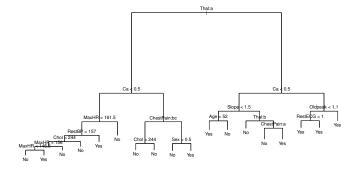
• O erro mínimo na validação cruzada ocorre na árvore de tamanho 3.



Exemplo: heart disease - HD



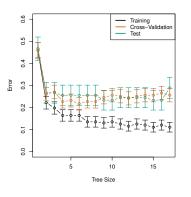
- Os dados contêm o diagnóstico de 303 pacientes com dores no peito:
 - * Yes: indica a presença de doença cardíaca;
 - * No: indica ausência de doença cardíaca;
- Os dados apresentam 13 preditores incluindo Age, Sex, Cho1, e outras medidas de funções cardíacas e pulmonar;

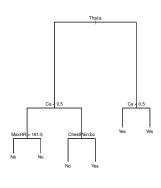


Exemplo: heart disease - HD



Após validação cruzada chegamos na árvore com seis terminal nodes;

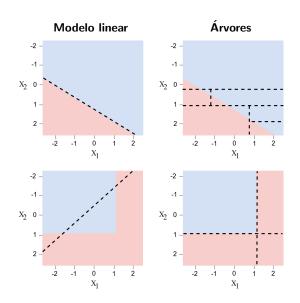




 Note que, em MaxHR temos duas respostas No. Isto se deve a um dos nós ser "puro" e o outro ser majoritariamente No.

Árvores versus modelos lineares





Prós e contras das Árvores de decisão



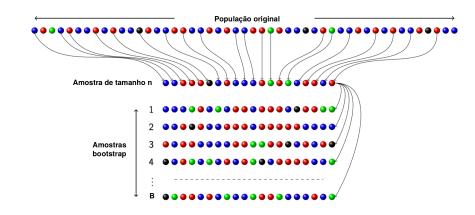
- ✓ Podem ser aplicadas em problemas de regressão e classificação;
- √ Lidam bem com dados faltantes;
- ✓ São simples e úteis para interpretação. Sendo muito bons nas etapas iniciais de um projeto;
- χ São mais simples do que deveriam. Por esse motivo, em termos de predição, não são competitivos com outras abordagens de aprendizado supervisionado;
- √ Mas, serve de base para outros métodos, como:
 - Bagging;
 - Random Forests;
 - Boosting.



Ensembles

Ideia do Bootstrap





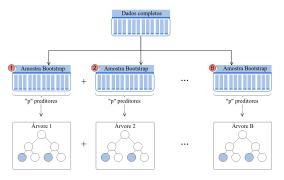


Bagging

Bagging



 Geramos B conjuntos de observações (bootstrapped). Treinamos o modelo a fim de obter a predição no ponto x;



• Em seguida, calculamos a média das predições (chamamos de bagging):

$$\hat{h}_{bag}(x) = \frac{1}{B} \sum_{b=1}^{B} \hat{h}^{b}(x).$$

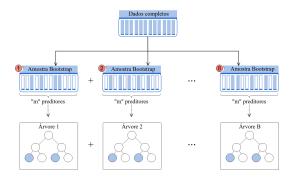


Random Forests

Random Forests



 No Random forests, para cada partição, temos uma seleção aleatória de m preditores, de um total de p (tipicamente, m ≈ √p);

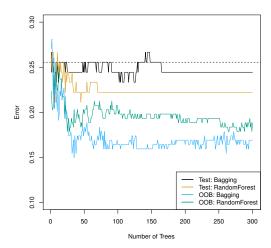


 Assim, forçamos com que diferentes preditores sejam escolhidos (decorrelating the trees). Se m = p, estaremos no método Bagging.

Exemplo: Heart data set

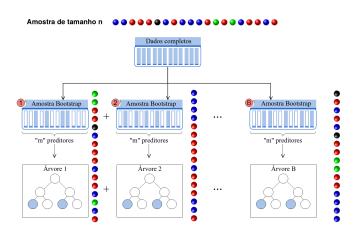


 Abaixo, o erro do teste como função de B. A linha tracejada representa o erro utilizando uma árvore somente;



Out-of-Bag Error Estimation

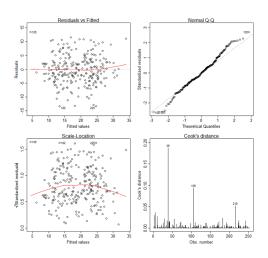






Métodos boosting







• Lembrando de regressão

$$\underbrace{\sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2}_{SQT} = \underbrace{\sum_{i=1}^{n} \left(\hat{y}_i - \bar{y}\right)^2}_{SQR} + \underbrace{\sum_{i=1}^{n} \left(y_i - \hat{y}\right)^2}_{SQE}.$$

• E, geometricamente, temos

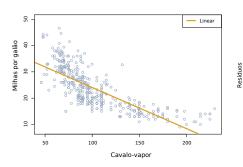


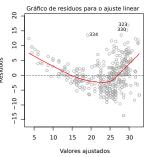
 Isso quer dizer que toda variabilidade não explicada pela regressão ficará no resíduo (variáveis e funções delas!).



 No exemplo abaixo, estamos avaliando a relação entre consumo de combustível e potência do automóvel.

$$mpg = \beta_0 + \beta_1 \times (cavalo vapor) + \varepsilon$$

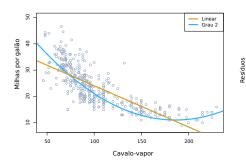


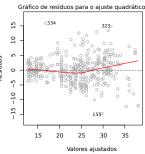




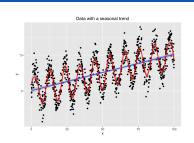
 No exemplo abaixo, estamos avaliando a relação entre consumo de combustível e potência do automóvel.

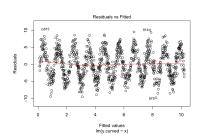
$$mpg = \beta_0 + \beta_1 \times (cavalo vapor) + \beta_2 \times (cavalo vapor)^2 + \varepsilon$$

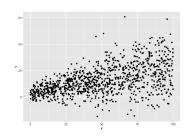


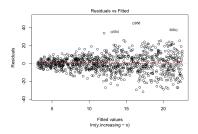








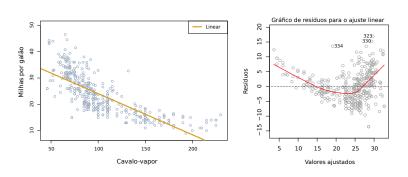




Métodos boosting



 $mpg = \beta_0 + \beta_1 \times (cavalo vapor) + residuo$



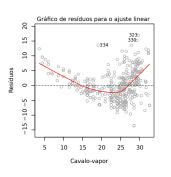
 $residuo = \beta_2 \times (cavalo \ vapor)^2 + residuo 2$

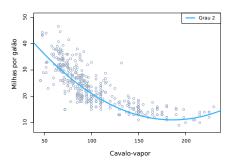
$$mpg = \beta_0 + \beta_1 \times (cavalo \ vapor) + \beta_2 \times (cavalo \ vapor)^2 + residuo2$$

Métodos boosting



 $mpg = \beta_0 + \beta_1 \times (cavalo vapor) + residuo$





 $residuo = \beta_2 \times (cavalo \ vapor)^2 + residuo 2$

$$mpg = \beta_0 + \beta_1 \times (cavalo vapor) + \beta_2 \times (cavalo vapor)^2 + residuo2$$

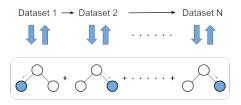


Adaptive Boosting (AdaBoost)

Adaptive Boosting (AdaBoost)



- O princípio básico do Boosting é propor um modelo básico (weak learner)
 e o aprimorá-lo em cada iteração.
- O processo consiste em filtrar os resultados corretos, e concentrar-se naqueles que o modelo n\u00e3o soube lidar;



 Nesse caso, os weak learners, são árvores de decisão com uma separação apenas (chamada de decision stumps).

Como o algoritmo funciona?



- 1 Inicie com $\hat{h}(x) = 0$ e $r_i = y_i$, para todo i dos dados de treino;
- 2 Para b = 1, 2, ..., B, repita:
 - a) Ajuste a árvore \hat{h}^b com d divisões para os dados de treino (X, r);
 - b) Atualize \hat{h} adicionando uma nova versão à árvore anterior:

$$\hat{h}(x) \leftarrow \hat{h}(x) + \alpha \hat{h}^b(x).$$

c) Atualize os resíduos,

$$r_i \leftarrow r_i - \alpha \hat{h}^b(x_i).$$

O modelo de saída fica então,

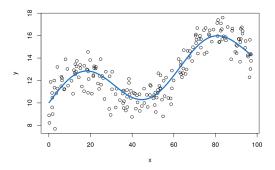
$$\hat{h}(x) = \sum_{b=1}^{B} \alpha \hat{h}^b(x).$$

Exemplo simulado



• Considere o exemplo simulado, obtido a partir da função:

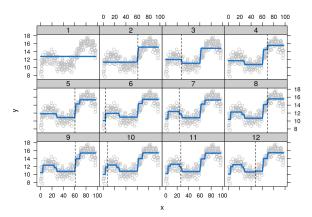
$$f(x) = 10 + 0,05x + 2\sin\left(\frac{x}{10}\right)$$



Exemplo simulado



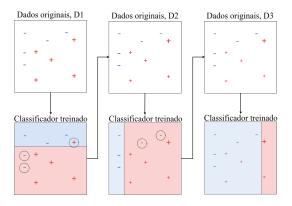
 O processo consiste em analisar o resíduo decorrente do modelo anterior e somar novas árvores, suprindo tais deficiências.



Adaptive Boosting (AdaBoost)



 A ideia é ponderar os erros para que nas próximas árvores eles tenham mais importância. Em seguida, combinar os classificadores.

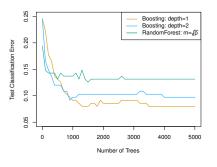


 Não vamos entrar em detalhes teóricos da abordagem. Para o aluno interessado sugere-se Elements of Statistical Learning, capítulo 10.

Exemplo: Expressão gênica



 Os dados consistem na medida de expressão de 4.718 genes dos tecidos de 349 pacientes;



- Cada paciente possui um marcador qualitativo (de 15 níveis):
 - ⋆ Normal;
 - Ou 14 tipos de câncer;

 A forma de construção do boosting (baseado nas árvores anteriores) faz com que ele faça um bom trabalho mesmo com uma partição apenas.

Referências



- James, G., Witten, D., Hastie, T. e Tibshirani, An Introduction to Statistical Learning, 2013;
- Hastie, T., Tibshirani, R. e Friedman, J., The Elements of Statistical Learning, 2009;
- Lantz, B., Machine Learning with R, Packt Publishing, 2013;
- Tan, Steinbach, and Kumar, Introduction to Data Mining, Addison-Wesley, 2005;
- Some of the figures in this presentation are taken from "An Introduction to Statistical Learning, with applications in R" (Springer, 2013) with permission from the authors: G. James, D. Witten, T. Hastie and R. Tibshirani