

Universidade Federal do Paraná Laboratório de Estatística e Geoinformação - LEG




Classificação

Eduardo Vargas Ferreira

Tipos de aprendizado





Introdução




• Em muitos problemas, a variável Y assume valores em um conjunto não ordenado \mathcal{C} , por exemplo:

```
⋆ E-mail ∈ {spam, ham};

⋆ Dígito ∈ {0,1,...,9};

⋆ Alzheimer ∈ {com Alzheimer, sem Alzheimer};
```

Nestes casos, estamos diante de um problema de classificação;



Introdução



Considere um problema binário, em que Y assume somente dois valores,
 c₁ ou c₂. Para um dado x, escolheremos c₁ quando

$$P(Y = c_1|x) \geq P(Y = c_2|x),$$

 Tal classificador é conhecido como Classificador de Bayes. Escolhemos nossa função, tal que,

$$h(x) = \underset{d \in \{c_1, c_2\}}{\operatorname{argmax}} P(Y = d|x).$$

O classificador de Bayes é um padrão ouro inalcançável!

Plug-in classifier



• A solução é então estimar $\mathrm{P}(\mathit{Y} = c_i | \mathbf{x})$, para $i \in \mathcal{C}$, ou seja

- \star Estimamos P(Y = c|x) para cada categoria $c \in C$;
- * Tomamos $\hat{h}(x) = \underset{c \in \mathcal{C}}{\operatorname{argmax}} \ \widehat{P}(Y = c|x).$


Essa abordagem é conhecida como plug-in classifier.






• O KNN estima a distribuição condicional de Y|X de acordo com as classes dos K vizinhos de determinada observação x_0 , ou seja:


$$P(Y=j\mid X=x_0)=\frac{1}{K}\sum_{i\in\mathcal{N}_0}\mathbb{I}(y_i=j).$$









• A escolha de K tem um efeito drástico no classificador KNN obtido








 Temos que escolhê-lo de acordo com o resultado do teste. A linha pontilhada representa o classificador de Bayes.





 Temos que escolhê-lo de acordo com o resultado do teste. A linha pontilhada representa o classificador de Bayes.







Regressão logística

Exemplo: Inadimplência no cartão de crédito (1929)



- Nosso objetivo é prever se um cliente será ou não inadimplente no próximo mês. Para tanto, temos três variáveis explicativas:
 - * Student: se o cliente é ou não estudante:
 - Income: rendimento anual do cliente;
 - * Balance: o valor devido no mês atual.






Podemos utilizar regressão linear?




• Suponha que para classificação da variável Default codificamos da forma:

$$Y = \begin{cases} 0, & \text{se No }, \\ 1, & \text{se Yes }. \end{cases}$$

• Podemos simplesmente realizar uma regressão linear de Y em X e classificar como Yes se $\hat{Y} > 0.5$?





Regressão logística



A regressão logística utiliza a forma

$$P(Y = 1|X) = rac{e^{eta_0 + eta_1 X}}{1 + e^{eta_0 + eta_1 X}}.$$

• Com um pouco de algebrismo, chegamos em

$$\log\left[\frac{P(Y=1|X)}{1-P(Y=1|X)}\right]=\beta_0+\beta_1X.$$

Variável	Coeficiente Erro padrão		Estatística t	p-valor
Intercepto	-3,5041	0,0707	-49,55	< 0,0001
Student[Yes]	0,4049	0,1150	3,52	0,0004

$$log \left[\frac{P(\text{Default} = \text{Yes} \mid \text{Student})}{1 - P(\text{Default} = \text{Yes} \mid \text{Student})} \right] = -3,5241 + 0,4049 \cdot \text{Student} \text{[Yes]}$$

Regressão logística com várias variáveis



Agora o caso de mais de um preditor, o modelo geral torna-se

$$\log \left[\frac{P(Y=1|X)}{1-P(Y=1|X)} \right] = \beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p.$$


Variável	Coeficiente	Erro padrão	Estatística t	p-valor	
Intercepto	-10,8690	0,4923	-22,08	< 0,0001	
Balance	0,0057	0,0002	24,74	< 0,0001	
Income	0,0030	0,0082	0,37	0,7115	
Student[Yes]	-0,6468	0,2362	-2,74	0,0062	


 Por que o coeficiente de Student é negativo agora, enquanto era positivo anteriormente? Confundimento.

Confundimento



 Os resultados são diferentes, especialmente quando existe correlação entre os preditores.







Regressão multinomial

Regressão multinomial



 Até agora, discutimos o caso de regressão logística com duas classes. É fácil generalizar para mais classes

$$P(Y = k | X) = \frac{e^{\beta_{0k} + \beta_{1k} X_1 + \dots + \beta_{pk} X_p}}{\sum_{l=1}^{K} e^{\beta_{0l} + \beta_{1l} X_1 + \dots + \beta_{pl} X_p}}$$

 Por exemplo, podemos classificar um paciente na sala de emergência de acordo com seu sintoma

$$Y = \begin{cases} 1, & \text{se AVC}, \\ 2, & \text{se overdose de droga}, \\ 3, & \text{se ataque epilético}. \end{cases}$$

Outra abordagem



 Uma alternativa para estimar P(Y|X) consiste em modelar a distribuição de X, em cada classe separadamente, utilizando o Teorema de Bayes:

$$P(Y = k | X = x) = \frac{P(Y = k)P(X = x | Y = k)}{P(X = x)}$$

• Que escrevendo de outra forma fica

$$P(Y = k|X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^{K} \pi_l f_l(x)}$$


Então temos que


$$\delta_k(x) \propto \operatorname{argmax} \pi_k f_k(x)$$

Outra abordagem



• $\pi_k = P(Y = k)$ é a **probabilidade marginal** ou **priori** para classe k. Pode ser estimada utilizando as proporções amostrais em cada classe.






• $f_k(x) = P(X = x | Y = k)$ é a densidade para X na classe k (diferentes distribuições levam a diferentes métodos).





• Ao considerarmos para $f_k(x)$ a distribuição Normal em cada classe, nos leva à análise de discriminante linear ou quadrática, pois

$$\begin{array}{lll} \delta_k(x) & \propto & \operatorname{argmax} \ \pi_k f_k(x) \\ & = & \operatorname{argmax} \left\{ \log \pi_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} \langle x - \mu_k, \Sigma_k^{-1}(x - \mu_k) \rangle \right\}. \end{array}$$



$$\hat{\pi}_k = \frac{n_k}{n}$$

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i = k} x_i$$

$$\hat{\Sigma}_k = \frac{1}{n_k - 1} \sum_{i:y_i = k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^t$$




• Quando $f_k(x)$ possui matriz de covariância, Σ_k , diferente em cada classe, temos a análise de discriminante quadrático (ADQ)

$$\begin{array}{lll} \delta_k(x) & \propto & \operatorname{argmax} \ \pi_k f_k(x) \\ & = & \operatorname{argmax} \left\{ \log \pi_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^t \Sigma_k^{-1} (x - \mu_k) \right\}. \end{array}$$

• Se todas as classes compartilharem o mesmo $\Sigma = \sum_k \frac{n_k - 1}{n - K} \hat{\Sigma}_k$, estamos diante da análise de discriminante linear (ADL)

$$\begin{array}{ll} \delta_k(x) & \propto & \operatorname{argmax} \ \pi_k f_k(x) \\ & = & \operatorname{argmax} \left\{ \log \pi_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k + x^t \Sigma^{-1} \mu_k \right\}. \end{array}$$






llustração: p = 2 e k = 3 classes




• No exemplo abaixo, temos $\pi_1 = \pi_2 = \pi_3 = 1/3$;



 A linha pontilhada é conhecida como fronteira de decisão de Bayes (Bayes decision boundaries);

Exemplo: Iris Data

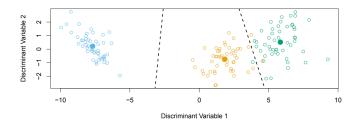




Exemplo: Iris Data



• Temos 4 variáveis, 3 espécies com 50 observações em cada classe;

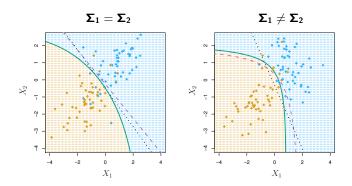


 Análise de discriminante linear classifica corretamente 147/150 observações dos dados de treino.

Exemplo simulado: Bayes, ADL e ADQ



 No exemplo, temos a fronteira de decisão de Bayes em rosa, ADL pontilhado e ADQ em verde, em um problema com 2 classes;



Regressão logística versus ADL



Regressão logística maximiza a verossimilhança condicional

$$\prod_{i} p(x_{i}, y_{i}) = \underbrace{\prod_{i} p(y_{i}|x_{i}) \prod_{i} g(x_{i})}_{logistica} \underbrace{\prod_{i} g(x_{i})}_{ignorado}$$


ADL maximiza a verossimilhança completa

$$\prod_{i} p(x_{i}, y_{i}) = \prod_{i} p(x_{i}|y_{i}) \prod_{i} p(y_{i})$$
normal f_{k} bernoulli π_{k}

Qual classificador escolher?




- Cenário 1: 20 observações em cada classe. Todas não correlacionadas e normalmente distribuídas;
- Cenário 2: Semelhante ao cenário 1, mas em cada classe, os preditores têm correlação de -0,5;
- Cenário 3: Semelhante ao cenário 1, mas com distribuição t de student.



Qual classificador escolher?



- Cenário 4: Os dados são normalmente distribuídos, com correlação de 0,5 em uma classe e -0,5 em outra;
- Cenário 5: As respostas foram geradas utilizando os preditores: X_1^2 , X_2^2 e $X_1 \times X_2$ (ou seja, limite de decisão quadrático);
- Cenário 6: As respostas foram geradas utilizando funções não lineares mais elaboradas.





Naive bayes

Naive bayes



 Se supusermos que as componentes de x são independentes condicionalmente à classe Y estamos diante do Naive Bayes;


• Naive Bayes assume distribuição normal, com Σ_k diagonal:

$$\delta_k(x) \propto log\left[\pi_k \prod_{j=1}^p f_{kj}(x_j)\right] = -\frac{1}{2} \sum_{j=1}^p \frac{(x_j - \mu_{kj})^2}{\sigma_{kj}^2} + log(\pi_k).$$

- Apesar de tal suposição não ser razoável, em muitos problemas ela é conveniente, e leva a bons classificadores.
- Lembre-se que estamos interessados classificar, e obter estimadores viciados não altera esta decisão.


Exemplo: Iris Data





Exemplo: Iris Data







Tipos de erro

Tipos de erro



• Voltando ao exemplo do cartão de crédito, temos a seguinte situação:

		Default observado Não Sim Total		
Default predito	Não Sim	9644 23	252 81	9896 104
	Total	9667	333	10000

- Tivemos $\frac{23+252}{10000}=2,75\%$ erros de classificação;
- Se classificarmos todos como Não, teríamos $\frac{333}{10000} = 3,33\%$ de erro;

Falso positivo: fração de negativos classificados como positivo, $\frac{23}{9667} = 0,2\%$;

Falso negativo: fração de positivos classificado como negativo, $\frac{252}{333} = 75,7\%$.


Variando o threshold



• Podemos mudar as taxas de erro, alterando a fronteira de decisão para algum valor $\in [0,1]$:

$$\widehat{P}(Default = Yes \mid Balance, Student) \ge threshold.$$


 Abaixo, em azul temos a taxa de falso negativo, em laranja falso positivo e em preto a taxa de erro total.



Curva ROC



 A curva ROC (receiver operator characteristic) nos ajuda nesta escolha do threshold. Ela apresenta as duas taxas de erro ao mesmo tempo.



Referências



- James, G., Witten, D., Hastie, T. e Tibshirani, An Introduction to Statistical Learning, 2013;
- Hastie, T., Tibshirani, R. e Friedman, J., The Elements of Statistical Learning, 2009;
- Lantz, B., Machine Learning with R, Packt Publishing, 2013;
- Tan, Steinbach, and Kumar, Introduction to Data Mining, Addison-Wesley, 2005;
- Some of the figures in this presentation are taken from "An Introduction to Statistical Learning, with applications in R" (Springer, 2013) with permission from the authors: G. James, D. Witten, T. Hastie and R. Tibshirani