

Universidade Federal do Paraná Laboratório de Estatística e Geoinformação - LEG



Gradiente descendente

Eduardo Vargas Ferreira

Solução de quadrados mínimos



Teorema: Seja $X \in \mathrm{M}_{n \times p}(\mathrm{R})$, com n > p e posto(X) = p. Definimos $J : \mathrm{R}^p \to \mathrm{R}$ da seguinte forma:

$$J(\beta) = \langle \boldsymbol{X}\beta - \boldsymbol{y}, \boldsymbol{X}\beta - \boldsymbol{y} \rangle \; ; \; \beta \in \mathbb{R}^p.$$

Então, o **Problema de Minimização**: encontrar $\hat{eta} \in \mathrm{R}^p$ tal que

$$J(\hat{\boldsymbol{\beta}}) = \min\{J(\boldsymbol{\beta}) ; \boldsymbol{\beta} \in \mathbb{R}^p\}$$

é equivalente ao Sistema Normal

$$\mathbf{X}^t \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^t \mathbf{y}.$$

que resulta em

$$\hat{\beta} = (\mathbf{X}^t \mathbf{X})^{-1} \mathbf{X}^t \mathbf{y}.$$



Método do Gradiente Descendente

Método do Gradiente Descendente

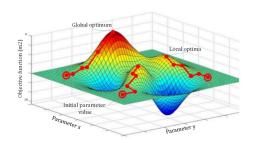


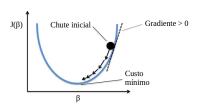
 O Gradiente Descendente (GD) é um método para encontrar o mínimo de uma função de forma iterativa:

Algoritmo: Escolha um chute inicial, $\boldsymbol{\beta}^{(0)} \in \mathrm{R}^{p}$, repita:

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} - \alpha_k \nabla J(\boldsymbol{\beta}^{(k)}), \ k = 0, 1, \dots$$

pare quando atingir convergência.

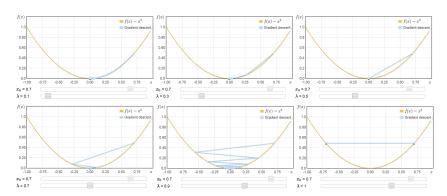




Taxa de aprendizagem α



- Taxa de aprendizagem controla o tamanho do passo em cada iteração;
- Selecionar o valor correto é crítico:
 - \star Se tomarmos α pequeno, o método fica lento;
 - \star Se α muito grande, o método diverge.

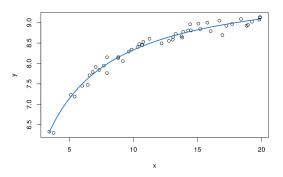


Exemplo simulado 1



• Considere os dados simulados a partir do modelo:

$$f(x_i, \theta) = \frac{\theta_a x_i}{\theta_v + x_i}, \quad \text{com} \quad (\theta_a, \theta_v)' = (10, 2).$$

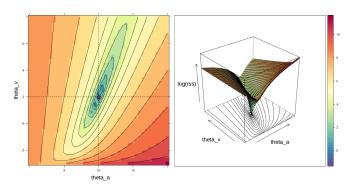


Exemplo simulado 1



• O nosso interesse será encontrar os valores de θ , que minimize a função:

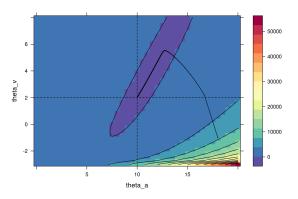
$$RSS = \sum_{i=1}^{n} \left(y_i - \frac{\theta_a x_i}{\theta_v + x_i} \right)^2.$$



Exemplo simulado 1



• Utilizamos os critérios de parada: $|\theta^{(k+1)} - \theta^{(k)}| < 0.0001$ ou 10000 iterações. E a taxa de aprendizado, α , de 0,001.



• O algoritmo convergiu para os pontos $(\theta_a, \theta_v) = (10, 03; 2, 05)$, na iteração 2412.

Prós e contras do GD



- ✓ Ideia simples e cada iteração é barata;
- ✓ Garantia de convergência para o mínimo local;
- ✓ Com vários algoritmos de segunda ordem para acelerar sua convergência;
- Muito rápido para matrizes bem condicionadas e problemas fortemente convexos;
- X Frequentemente é lento, pois problemas interessantes não são fortemente convexos ou bem condicionados;
- X Não lida com funções não diferenciáveis (dica: use o método Subgradiente);
- X Utiliza todos os dados de treinamento para estimar os parâmetros. Assim, para grandes bancos de dados, torna-se lento.



Gradiente Descendente Estocástico

Gradiente Descendente Estocástico (GDE)



 Considere o par (x_i, y_i) amostrado do treinamento. A atualização dos parâmetros é dada por

Algoritmo: Escolha um chute inicial, $\beta^{(0)} \in \mathbb{R}^{p+1}$, repita:

$$\boldsymbol{\beta}^{(k+1)} = \boldsymbol{\beta}^{(k)} - \alpha_k \nabla J(\boldsymbol{\beta}^{(k)}; \mathbf{x}_i, y_i), \ k = 0, 1, \dots$$

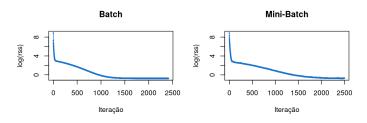
pare quando atingir convergência.

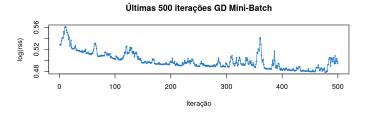
- No GDE a taxa de aprendizagem, α, é, tipicamente, menor do que o GD (batch). Isso ocorre, pois temos uma maior variância nas atualizações;
- Métodos mais sofisticados incluem o uso de Backtracking line search ou Exact line search.

Exemplo simulado 1 (continuação)



 Como era de se esperar, o método Mini-Batch utiliza mais iterações para atingir a convergência.





Prós e contras do GDE



- ✓ Convergência mais rápida, especialmente com grandes bancos de dados ou dados redundantes, p. ex.:
 - Imagine que temos dados de treino de tamanho 100.000;
 - Mas na verdade são 100 cópias de 1000;
 - Ou seja, padrões parecidos, com mesmo efeito;
 - Batch será, pelo menos, 100 vezes mais devagar.
- √ A trajetória estocástica permite escapar de um mínimo local;
- χ Prova da convergência é probabilística;
- χ Muitos métodos de segunda ordem não funcionam.



Gradiente boosting

Lembrando do método boosting



 No exemplo abaixo, estamos avaliando a relação entre consumo de combustível e a potência do automóvel.

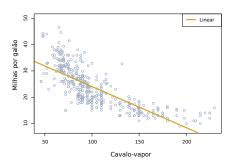
$$mpg = \beta_0 + \beta_1 \times (\text{cavalo vapor}) + \text{Resíduo}$$

$$\sum_{i=1}^{n} (y_i - \bar{y})^2 = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^{n} (y_i - \hat{y})^2$$

$$SQT$$

$$SQR$$

$$SQE$$

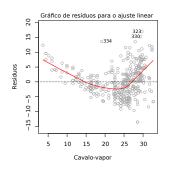


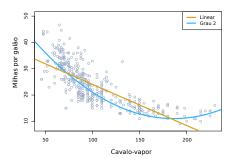


Lembrando do método boosting



Resíduo =
$$\beta_2 \times (\text{cavalo vapor})^2 + \text{Resíduo } 2$$





$$mpg = \underbrace{\beta_0 + \beta_1 \times (\text{cavalo vapor})}_{Parte1} + \underbrace{\beta_2 \times (\text{cavalo vapor})^2}_{Parte2} + \underbrace{\underbrace{\text{Res\'iduo 2}}_{Atualizado}}_{Atualizado}$$

Lembrando do método boosting



Considere o seguinte procedimento

$$Y = h(x) + \text{Resíduo} \tag{1}$$

• Se o Resíduo não for um ruído branco (mas algo correlacionado com Y)

$$Resíduo = g(x) + Resíduo 2$$
 (2)

Combinando (1) e (2)

$$Y = h(x) + g(x) + \text{Resíduo } 2$$

• Pode-se dizer que h(x) foi atualizada com uma parte do Resíduo, ou seja

$$h(x)^{(2)} = h(x)^{(1)} + g(x)$$

Como isto se relaciona com o Gradiente



• Queremos minimizar

$$J[y_i, h(x)] = \frac{1}{2n} \sum_{i=1}^n [y_i - h(x_i)]^2$$

• Derivando com relação a $h(x_i)$ temos

$$\frac{\partial J[y_i,h(x)]}{\partial h(x_i)}=h(x_i)-y_i$$

Podemos interpretar os resíduos como o negativo do gradiente

Resíduos =
$$y_i - h(x_i) = -\frac{\partial J[y_i, h(x)]}{\partial h(x_i)}$$

Resíduo \Leftrightarrow Negativo do gradiente Atualizar $h(x_i)$ com o resíduo \Leftrightarrow Atualizar $h(x_i)$ com o negativo do gradiente

Gradiente boosting



Resíduo \Leftrightarrow Negativo do gradiente Atualizar $h(x_i)$ com o resíduo \Leftrightarrow Atualizar $h(x_i)$ com o negativo do gradiente

$$h(x_i)^{(k+1)} = h(x_i)^{(k)} + \text{Residuo}$$

$$h(x_i)^{(k+1)} = h(x_i)^{(k)} - \frac{\partial J(y_i, h(x))}{\partial h(x_i)}$$

Algoritmo: Escolha um chute inicial, $h(x_i)^{(0)}$, e:

- * Calcule $-\frac{\partial J(y_i, h(\mathbf{x})^{(k)})}{\partial h(\mathbf{x}_i)^{(k)}}$;
- * Ajuste um modelo de regressão $g(x_i)^{(k)}$ baseado no negativo do gradiente, e faça:

$$h(x_i)^{(k+1)} = h(x_i)^{(k)} + \rho g(x_i)^{(k)}, \ k = 0, 1, \dots$$

pare quando atingir convergência.

Outras funções perda



Soma dos desvios absolutos (SDA)

$$J[y_i, h(x)] = \frac{1}{n} \sum_{i=1}^{n} |y_i - h(x_i)|$$

$$-\frac{\partial J[y_i, h(x)]}{\partial h(x_i)} = sign[y_i - h(x_i)] = \begin{cases} 1, & \text{se } |y_i - h(x_i)| < 0, \\ -1, & \text{se } |y_i - h(x_i)| > 0 \end{cases}$$

Huber-M cost

$$J[y_i, h(\mathbf{x})] = \frac{1}{n} \sum_{i=1}^n \begin{cases} \frac{1}{2} [y_i - h(\mathbf{x}_i)]^2, & \text{para } |y - h(\mathbf{x}_i)| \leq \delta, \\ \delta |y_i - h(\mathbf{x}_i)| - \frac{1}{2} \delta^2, & \text{caso contrário.} \end{cases}$$

$$-\frac{\partial J[y_i,h(x)]}{\partial h(x_i)} = \begin{cases} y_i - h(x_i), & \text{se } |y_i - h(x_i)| \leq \delta, \\ \delta sign[y_i - h(x_i)], & \text{caso contrário.} \end{cases}$$

• Para mais detalhes, veja • Greedy Function Approximation: A Gradient Boosting Machine





Modelos de Regressão

Extreme Gradient Boosting



 XGBoost é o algoritmo mais popular de ML atualmente. Desde a sua criação, em 2014, tornou-se o "true love" dos competidores do Kaggle;



- booster[default=gbtree]
 - * Determina o tipo de booster (gbtree, gblinear ou dart).
- nrounds[default=100]
 - Controla o número de iterações. Para classificação, é similar ao número de árvores.
- eta[default=0.3][range: (0,1)]
 - ★ Controla a taxa de aprendizado. Tipicamente, utilizamos valores entre 0,01 e 0,3.
- max_depth[default=6][range: (0,Inf)]
 - * Controla o tamanho de cada árvore. Geralmente, utilizamos árvores menores, para evitar o superajuste.



- eval_metric [no default, depends on objective selected]
 - * Métrica utilizada para avaliar o modelo.
- subsample[default=1][range: (0,1)]
 - Controla o tamanho da amostra em cada árvore. Tipicamente, são valores entre 0,5 e 0,8.
- colsample_bytree[default=1][range: (0,1)]
 - * Controla o número de variáveis apresentada à árvore. Tipicamente, são valores entre 0,5 e 0,9.
- lambda[default=0]
 - * Controla o penalty ℓ_2 nos pesos (equivalente ao Ridge). Utilizado para evitar superajuste.

Referências



- James, G., Witten, D., Hastie, T. e Tibshirani, An Introduction to Statistical Learning, 2013;
- Hastie, T., Tibshirani, R. e Friedman, J., The Elements of Statistical Learning, 2009;
- Lantz, B., Machine Learning with R, Packt Publishing, 2013;
- Tan, Steinbach, and Kumar, Introduction to Data Mining, Addison-Wesley, 2005;
- Some of the figures in this presentation are taken from "An Introduction to Statistical Learning, with applications in R" (Springer, 2013) with permission from the authors: G. James, D. Witten, T. Hastie and R. Tibshirani