

Universidade Federal do Paraná Laboratório de Estatística e Geoinformação - LEG



Regularização


Eduardo Vargas Ferreira


Estimando os coeficientes



 Quando estimamos os parâmetros da regressão por mínimos quadrados ordinários, estamos interessados na seguinte minimização:

$$min\left\{J\left[y_{i},h(\boldsymbol{x})\right]\right\}=min\left\{\sum_{i=1}^{n}\left(y_{i}-\beta_{0}-\sum_{j=1}^{p}\beta_{j}x_{ij}\right)^{2}\right\}$$






Bias-Variance Trade-Off



Uma solução é flexibilizar o modelo admitindo certo vício das estimativas.





$$\mathbb{E}[y_0 - h(\mathbf{x}_0)]^2 = \operatorname{Var}[h(\mathbf{x}_0)] + [\operatorname{Vicio}(h(\mathbf{x}_0))]^2 + \operatorname{Var}(\varepsilon).$$

Problemas dos mínimos quadrados ordinários (eg



- Em situações com "small n, large p" a maioria dos métodos modernos de análise de dados falha, por diferentes razões, p. ex.:
 - * Modelos Lineares Generalizados: falham, pois a matriz do modelo não tem posto completo;
 - * Random Forests falham, pois a probabilidade de selecionar variáveis importantes diminui muito.
 - * Análise de Clusters e métodos baseados em distâncias no plano cartesiano falham devido à "maldição da dimensionalidade".









Regularização

5


Uma solução é a Regularização



• Regulamos o número de variáveis, impondo um custo ao algoritmo:

$$\min_{oldsymbol{eta}} \sum_{i=1}^n \left(y_i - eta_0 - \sum_{j=1}^p eta_j x_{ij}
ight)^2$$
 sujeito a $g(oldsymbol{eta}) < t, \, \mathrm{com} \,\, t > 0$

• $g(\beta)$ representa a função penalty (shrinkage penalty).



Como fazemos isso?



Estamos diante de uma otimização com restrição:

$$\min_{oldsymbol{eta}} \sum_{i=1}^n \left(y_i - eta_0 - \sum_{j=1}^p eta_j x_{ij}
ight)^2$$
 sujeito a $g(oldsymbol{eta}) < t, \ \mathrm{com} \ t > 0$

Fazemos isso aumentando a função objetivo:

$$\min_{oldsymbol{eta}} \sum_{i=1}^{n} \left(y_i - eta_0 - \sum_{j=1}^{p} eta_j x_{ij} \right)^2 + \lambda g(oldsymbol{eta}), \ \mathrm{com} \ \lambda > 0$$

• $t \in \lambda$ são inversamente proporcionais.

Função penalty



Temos a função objetivo aumentanda:

$$\min_{oldsymbol{eta}} \sum_{i=1}^n \left(y_i - eta_0 - \sum_{j=1}^p eta_j x_{ij} \right)^2 + \lambda g(oldsymbol{eta}), \ \mathrm{com} \ \lambda > 0$$

Utilizaremos a família das potências para penalizar o modelo:

$$\min_{\beta} \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} |\beta_j|^q$$

• λ é o tuning parameter, determinado separadamente. Ele controla o impacto do *penalty*, $g(\beta)$, nas estimativas dos parâmetros.

Padronização dos preditores



- Os coeficientes obtidos por mínimos quadrados ordinários são equivariantes por transformação de escala;
- Na regressão penalizada, $\mathbf{X}_j\hat{\beta}_{j,\lambda}^{\textit{restrito}}$ depende não somente de λ , mas da escala do j-ésimo preditor.

$$\min_{\beta} \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} \left| \beta_j \right|^q$$

• Diante disso, deve-se padronizar os preditores na regressão penalizada:

$$\tilde{x}_{ij} = \frac{x_{ij}}{\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(x_{ij} - \bar{x}_{j}\right)^{2}}}.$$



Penalização Ridge

q = 2 - Penalização Ridge




• Neste caso, o problema de otimização utiliza o penalty ℓ^2 :

$$\min_{oldsymbol{eta}} \; \sum_{i=1}^n \left(y_i - eta_0 - \sum_{j=1}^p eta_j \mathsf{x}_{ij}
ight)^2 + \lambda \sum_{j=1}^p eta_j^2$$

• No caso de vetores em X ortonormais

$$\hat{eta}_{\lambda}^{R}=rac{\hat{eta}^{ extit{OLS}}}{1+\lambda}.$$




• Os $\beta's$ podem ser próximos de zero, mas não assumem esse valor.


Exemplos



 Inadimplência no cartão de crédito: o objetivo é prever se um cliente será ou não inadimplente no próximo mês.



 Exemplo simulado: foi gerado utilizando 45 preditores relacionados à resposta, em que nenhum dos verdadeiros β₁, β₂,..., β₄₅ eram zero.





Penalização Lasso


q=1 - Penalização Lasso



• Os coeficientes *Lasso*, $\hat{\beta}_{\lambda}^{L}$, minimizam a quantidade

$$\min_{oldsymbol{eta}} \sum_{i=1}^n \left(y_i - eta_0 - \sum_{j=1}^p eta_j x_{ij}
ight)^2 + \lambda \sum_{j=1}^p |eta_j|$$


• O penalty ℓ^1 funciona também como um selecionador de variáveis.



Exemplo simulado



 No exemplo abaixo temos 100 observações com p = 20,50 e 2000, das quais apenas 20 são relacionadas com a resposta;





 Os graus de liberdade, substituem o λ, e representam o número de parâmetros estimados não nulos.

Exemplo: Inadimplência no cartão de crédito (E)





Regressão Ridge





Regressão Lasso







Comparação entre Ridge e Lasso



 Este exemplo foi gerado utilizando 45 preditores relacionados à resposta, em que nenhum dos verdadeiros coeficientes β₁, β₂,..., β₄₅ eram zero;



• No exemplo seguinte, a resposta é função apenas de 2 dos 45 preditores. I.e., 43 dos verdadeiros coeficientes $\beta_1, \beta_2, \dots, \beta_{45}$ eram zero.






Penalização Elastic net

Elastic net



• Elastic net é um compromisso entre a regressão Ridge e Lasso. Os coeficientes elastic net, $\hat{\beta}_{\lambda}^{E}$, minimizam a quantidade

$$\min_{oldsymbol{eta}} \sum_{i=1}^n \left(y_i - eta_0 - \sum_{j=1}^p eta_j \mathsf{x}_{ij}
ight)^2 + \lambda \sum_{j=1}^p \left(lpha |eta_j| + (1-lpha)eta_j^2
ight)$$






Penalização horseshoe

q < 1 - Penalização horseshoe



- Ela favorece mais ainda a presença de 0's (maior esparsidade);
- Ou seja, tende a encontrar as elipses geradas pelos mínimos quadrados em cima dos eixos com mais frequência que Ridge e Lasso;



• E quando q = 0 voltamos ao Best subset selection.



Regressão com Componentes Principais


Análise de Componentes Principais (ACP)




- Suponha que temos a informação sobre a população (pop) em 100 cidades dos EUA e gasto com propaganda de determinada empresa (ad);
- Podemos resumir essas variáveis em apenas uma, Z_1 , da seguinte forma:

$$Z_1 = \phi_{11} \left(pop - \overline{pop} \right) + \phi_{21} \left(ad - \overline{ad} \right)$$
$$= 0.839 \times \left(pop - \overline{pop} \right) + 0.544 \times \left(ad - \overline{ad} \right).$$

• Tal que $Var(Z_1)$ seja o máximo possível.





Análise de Componentes Principais (ACP)



$$Z_1 = 0.839 \times (\text{pop} - \overline{\text{pop}}) + 0.544 \times (\text{ad} - \overline{\text{ad}})$$

$$= 0.839 \times (\text{pop} - \overline{\text{pop}}) + 0.544 \times (\text{ad} - \overline{\text{ad}})$$

$$= 0.839 \times (\text{pop} - \overline{\text{pop}}) + 0.544 \times (\text{ad} - \overline{\text{ad}})$$

$$= 0.839 \times (\text{pop} - \overline{\text{pop}}) + 0.544 \times (\text{ad} - \overline{\text{ad}})$$

$$= 0.839 \times (\text{pop} - \overline{\text{pop}}) + 0.544 \times (\text{ad} - \overline{\text{ad}})$$

2nd Principal Component

Regressão com Componentes Principais



• Considere que Z_1, Z_2, \ldots, Z_M (M < p) represente as combinações lineares das variáveis originais $X_j, j = 1, \ldots, p$:

$$Z_m = \sum_{j=1}^p \phi_{jm} X_j, \text{ com } m = 1, \dots, M.$$

 Assumindo que direção de máxima variabilidade é a mesma associada ao Y, podemos construir uma regressão utilizando as C.P's, da forma:

$$y_i = \theta_0 + \sum_{m=1}^M \theta_m z_{im} + \varepsilon_i$$
, com $i = 1, \dots, n$.


Mas, note que


$$\sum_{m=1}^{M} \theta_{m} z_{im} = \sum_{m=1}^{M} \theta_{m} \sum_{j=1}^{p} \phi_{jm} x_{ij} = \sum_{j=1}^{p} \sum_{m=1}^{M} \theta_{m} \phi_{jm} x_{ij} = \sum_{j=1}^{p} \beta_{j} x_{ij}.$$

Exemplos simulados



• Foi gerado utilizando 45 preditores relacionados à resposta, em que nenhum dos verdadeiros $\beta_1, \beta_2, \dots, \beta_{45}$ eram zero.






 Os resultados via PCR e Ridge são muito próximos. Pode-se dizer até que Ridge é uma versão contínua de PCR.

Exemplos simulados



 Os dados foram gerados, tal que a resposta dependesse apenas das 5 primeiras componentes principais.





 A PCR se sai melhor quando poucas componentes são necessárias para explicar a maior parte da variabilidade dos dados.

Exemplo: Inadimplência no cartão de crédito (eg



• Nestes dados o menor erro de validação foi obtido quando M=10. Equivalente aos mínimos quadrados.









Selecionando o tuning parameter

Selecionando o tuning parameter, λ



- Validação cruzada fornece uma maneira simples de resolver este problema:
 - (a) A partir de uma grade de valores de λ , calculamos a taxa de erro de validação (para cada λ);
 - **(b)** Escolhemos o valor de λ que fornece a menor taxa de erro;
 - (c Ajustamos novamente o modelo, utilizando todas as observações disponíveis, com o valor de λ encontrado anteriormente.







Exemplo simulado



• Este exemplo foi gerado utilizando 45 preditores, em que 43 dos verdadeiros coeficientes $\beta_1, \beta_2, \dots, \beta_{45}$ eram zero.



• Aplicamos validação cruzada 10 - fold para selecionar o melhor λ .



Referências



- James, G., Witten, D., Hastie, T. e Tibshirani, An Introduction to Statistical Learning, 2013;
- Hastie, T., Tibshirani, R. e Friedman, J., The Elements of Statistical Learning, 2009;
- Lantz, B., Machine Learning with R, Packt Publishing, 2013;
- Tan, Steinbach, and Kumar, Introduction to Data Mining, Addison-Wesley, 2005;
- Some of the figures in this presentation are taken from "An Introduction to Statistical Learning, with applications in R" (Springer, 2013) with permission from the authors: G. James, D. Witten, T. Hastie and R. Tibshirani